

數位人頭像唇形同步與逐字標示字幕

分析重點摘要

專案 cooleng_with_avatar_sync · 2026-06-19

分析依據：已閱讀現有程式碼（synthesizer.ts、AudioPlayer.svelte、question-answering 路由、types.ts），並對所有開源方法與 Azure 能力逐項查核。完整報告見《數位人頭像唇形同步_新功能技術分析報告.docx》。

最關鍵的結論 — 門檻比直覺低很多

影片裡「邊說、邊對嘴、邊逐字標示」需要兩個最難的訊號（嘴型序列、單字時間軸）。本專案已相依 Azure Speech SDK，它在 TTS 合成當下就原生吐出這兩者：

- visemeReceived → ARKit 相容 55-blendshape @60fps（驅動 3D 對嘴；需 SSML 加 `<mstts:viseme type="FacialExpression"/>`）。
- WordBoundary → 每個單字的 audioOffset/duration（tick÷10000=ms）+ textOffset/wordLength（驅動逐字字幕，不需另外導入 forced alignment 模型）。

一句話總結

真正的工程不在「生成對齊資訊」，而在「把它乾淨地接到瀏覽器端的頭像 + 字幕時間軸」。

推薦的 2-3 種開源方法（皆有 GitHub）

	方法	開源 repo	授權	適用
A 首選	TalkingHead.js + Azure viseme	met4citizen/TalkingHead	MIT	瀏覽器原生 3D、無需 GPU、與現有架構最契合
B 備選	MuseTalk 即時 2D 神經對嘴	TMElyralab/MuseTalk	MIT	照片級寫實，但需 GPU 後端 + 串流

	方法	開源 repo	授權	適用
C 備選	Wav2Lip / NVIDIA Audio2Face	Rudrabha/Wav2Lip · NVIDIA/Audio2Face-3D	非商業 / MIT*	基準對照 / 高品質 3D（需 NVIDIA GPU）

**Audio2Face 程式碼多為 MIT，模型權重採 NVIDIA 自有授權；star 數與授權以查核日 2026-06-19 為準，使用前請再確認。*

需額外新增的功能

- Synthesizer 播放時鐘重構（P0 阻塞性前置）：讓 viseme/字幕能對齊到音訊 currentTime。
- LLM 串流回覆通道（逐 token → 即時 TTS）。
- barge-in 打斷處理、頭像資產管線、降級策略、音檔+時間軸保存回放。

路線圖：P0–P5 分階段；MVP = P0+P1+P2（逐字字幕 + 3D 頭像對嘴），完全不需 GPU。

需你決定的方向

報告以「3D 風格化頭像（方法 A）」為主線推薦，因為最省力且可商用。若教學上必須是「真人臉」，才需走方法 B 的 GPU 路線。兩條路報告皆已寫明——看完後告訴我先做哪一條，即可進入實作。

備註：報告中所有事實（repo、授權、Azure 事件欄位格式）均經查核；少數項目（star 數、Audio2Face 權重授權、特定 voice 的 WordBoundary 邊界值）已於報告內標註「使用前請再確認」。